ECE 253 课程项目计划：手机拍摄文档的 OCR 预处理

Oct 1, 2026 · @Harry

1. 项目概述

本项目研究手机随手拍的文档为什么 OCR 识别不准，并用图像处理方法把准确率拉回来。拍坏的原因很多，我们只盯三种最常见的：运动模糊、阴影、透视畸变。每种缺陷单独做预处理，再看识别错误率降了多少，最后研究三种缺陷叠加时该怎么排预处理顺序。

要回答的四个问题

1. 三种缺陷各自让 OCR 的错误率（CER / WER）掉了多少？
2. 传统图像处理方法能恢复多少？和 AI 方法比差距在哪？
3. 针对自己采集的数据调整现有方法之后，比原版是否更好？
4. 三种缺陷叠加时，预处理的先后顺序怎么排最合理？

预期产出

- 一套自采的手机拍文档数据集，带已知的原文本作为 ground truth
- 三条预处理流水线，每条至少包含一个传统方法和一个对照方法
- 带和不带预处理的 OCR 对比结果，覆盖公开数据集和自采数据
- 三缺陷叠加的预处理顺序消融实验
- Proposal、两次展示（11/18–20、12/5–7）、最终报告（12/11）

2. Handout 要求对照与团队规模

先要确认一件事：handout 写的是 2 或 3 人一组，一个人做需要先问老师或助教。 组队表 10/6 截止，所以这件事本周内就该问清楚。如果最后能单人，下面的计划直接用；如果被要求组队，计划本身是按 artifact 切的，可以直接一人认领一块。

Handout 要求	本计划怎么满足
团队 2–3 人	单人需先获批准（10/6 前确认）
每人研究一个独立的 artifact	三种都做，其中一种做深、另两种做到可对比即可（见第 8 节）

Handout 要求	本计划怎么满足
自采数据，加上现有数据集	自采 30–50 页文档，三种拍摄条件；公开数据集补充
每个 artifact 至少两种方法，其中一种是传统方法	每个 artifact 两个传统方法（主方法加对照方法），AI 模型只作可选参考线
针对自采数据修改现有方法	每个 artifact 至少一处自适应改进，并和原版对比
带与不带预处理的对比	CER / WER 为主，PSNR / SSIM 为辅
讨论多个 artifact 的组合	三缺陷叠加实验和预处理顺序消融
写明各成员贡献百分比	单人为 100%，报告里按此说明

3. 技术方案：三种缺陷的预处理

每种缺陷都按同一个套路走：先写出退化模型，再实现一个传统方法（核心部分自己写，不只调库），再接第二个传统方法做对照，最后针对自采数据做一处改进。这门课是图像处理，所以主线两个方法都用传统技术，AI 模型只当可选的参考线，时间不够就不做。

3.1 运动模糊

- **退化模型**：g = h * f + n，h 是直线运动的 PSF（长度 L、方向 θ），n 是噪声。
- **传统方法**：先估 PSF，再做 Wiener 反卷积。PSF 用频谱里的暗条纹或倒谱估长度和方向；Wiener 滤波在频域自己写一遍。
- **对照方法**：同样是传统方法，用 Richardson-Lucy 迭代反卷积，迭代次数当作正则参数来调；时间够的话再加稀疏梯度先验（L0 正则）做盲去模糊。Wiener 是频域一次性求解，RL 是迭代的最大似然解，两者在噪声放大和振铃上的差别就是分析内容。NAFNet 之类的 AI 模型只作为可选的参考线。
- **针对自采数据的改进**：噪声参数 K 和核大小不用固定值，按文字笔画宽度和自采图的噪声水平来定。
- **分析重点**：K 取值对振铃和噪声放大的影响；PSF 估错一点时结果会差多少。
- **用到的课程知识**：图像退化模型、傅里叶变换、逆滤波、Wiener 滤波、PSF 估计、振铃效应。

3.2 阴影

- **退化模型**：I = L × R，也就是光照乘反射。阴影属于光照项的低频变化，文字属于反射项的高频部分。
- **传统方法**：用大核形态学闭运算或中值滤波估背景光照，原图除以背景，再用 Otsu 或 Sauvola 自适应阈值二值化。第二个传统方法见下面的对照方法。
- **对照方法**：同态滤波（对数域加高通）和 Retinex（单尺度、多尺度），它们和背景除法都是在估计光照项，只是估计方式不同，放在一起比较。BEDSR-Net 这类去阴影网络只作为可选的参考线。
- **针对自采数据的改进**：背景估计的核大小按文字行高自适应，不用固定值，避免核太小把大字当成背景擦掉。
- **分析重点**：核大小和阈值窗口怎么影响细笔画；手遮住的硬边阴影和灯光造成的软阴影，哪种更难。
- **用到的课程知识**：光照-反射模型、同态滤波、形态学运算、Retinex、Otsu / Sauvola 阈值。

3.3 透视畸变

- **退化模型**：斜着拍时，文档平面到图像平面是一个单应变换，3×3 矩阵，8 个自由度。
- **传统方法**：Canny 边缘，再用轮廓多边形逼近找文档四个角点，求单应矩阵，用双线性或双三次插值重采样得到正视图。
- **对照方法**：另一条传统路线，用 Hough 直线加 RANSAC 拟合文档边界求单应矩阵，或者用文本行方向（投影轮廓、Radon 变换）估计倾斜和透视，再和轮廓角点法比较稳健性。纸张弯曲单应变换处理不了，这部分只做定性讨论；DocTr 等 AI 矫正模型只作为可选的参考线。
- **针对自采数据的改进**：角点被手挡住或拍出画面时加兜底策略，例如用 Hough 直线延长求交点，或退化到用文本行方向估计旋转和倾斜。
- **分析重点**：角点检测失败率；插值方式对文字边缘清晰度的影响；平整纸和弯曲纸的差别。
- **用到的课程知识**：几何变换、单应矩阵、边缘检测、Hough 变换、图像插值。

4. 下游 OCR 与组合实验

OCR 只是评测工具，不是项目重点。 主识别器用 Tesseract，版本和参数（页面分割模式、语言）全程固定。PaddleOCR 作为可选的第二个识别器，用来检查结论是不是只对 Tesseract 成立。Tesseract 内部自带二值化，所以去阴影的结果要同时测灰度图和二值图两种输入。

组合实验回答 handout 里“多个 artifact 叠加”的要求。 三种缺陷叠加时，预处理有 3! = 6 种顺序，全部跑一遍，加上不处理的基线共 7 组。

编号	预处理顺序	说明
P0	不处理	基线
P1	去模糊 → 矫正 → 去阴影	假设最优：成像时先有光照，再被相机几何投影，最后被模糊，复原就按逆序来；先矫正会改变模糊核，所以去模糊放最前
P2	去模糊 → 去阴影 → 矫正	穷举对照
P3	矫正 → 去模糊 → 去阴影	穷举对照
P4	矫正 → 去阴影 → 去模糊	穷举对照，也是“先把页面摆正”的直觉做法
P5	去阴影 → 去模糊 → 矫正	穷举对照
P6	去阴影 → 矫正 → 去模糊	穷举对照

这里的假设是用成像模型推出来的，不一定对，实验结果和假设不一致也是有价值的发现，报告里要分析原因。

叠加数据有两个来源：一是真实拍摄的叠加组；二是用清晰的自采图按成像顺序合成（先加阴影，再做透视，最后加模糊），这样每个环节的参数是已知的，可以单独检查某一步出了多少错。

5. 数据方案

自采数据是 handout 的硬要求：至少 30 页文档，每页在四种条件下拍摄，约 360 张图。 页数能多则多，上限 40 页，再多一个人拍不过来。

文档选取：打印的论文页、书页、小票和表格各占一部分，字号和排版要有差别。全部用自己有文字层的 PDF 打印，这样原文本可以直接从 PDF 里提取，不用手标 ground truth，PDF 渲染出来的图还能当合成数据的清晰原图。

拍摄条件	每页张数	怎么拍
清晰基准	1	平放、光线均匀、尽量稳住，作为这一页的参照
运动模糊	3	手抖、边走边拍、快速平移，模糊方向和程度尽量不同
阴影	3	手遮住、台灯侧照、身体挡光，硬阴影和软阴影都要有

拍摄条件	每页张数	怎么拍
透视畸变	3	约 15°、30°、45° 的倾斜角度，页面保持平整
三种叠加	2	同时倾斜、有阴影、移动中拍

拍摄约定：至少用两部手机，关掉文档扫描模式和自动美化，固定原始分辨率。每张图记录手机型号、光线、大致角度，存进一个元数据 CSV。文件名统一成 `doc编号_条件_序号.jpg`。

数据划分：按页划分，约三分之一的页用来调参，其余用来最终测试，同一页的图不能同时出现在两边，否则调参会泄漏到测试结果里。

一个要注意的限制：真实拍摄的图和清晰基准图不是逐像素对齐的，所以 PSNR / SSIM 在真实数据上算不了，只能用 OCR 错误率评测。PSNR / SSIM 只用在合成数据上，那里的清晰原图是已知的。

公开数据集用作补充和对照，候选如下，下载方式和许可要实际核对后再定。

类型	候选	用在哪
手机拍文档	SmartDoc 系列	透视畸变和整体 OCR 评测
文档几何畸变	DocUNet 相关数据	透视和弯曲矫正
去模糊	公开的真实模糊数据集，或文本去模糊数据集	运动模糊
文档阴影	Kligler 等人的阴影文档数据	阴影

6. 评测指标与实验矩阵

主指标是 OCR 的字符错误率（CER）和词错误率（WER），判断预处理有没有用就看它们降没降。

```
CER = (S + D + I) / N
```

其中 S、D、I 分别是识别结果相对原文本的替换、删除、插入字符数，N 是原文本的字符数。WER 的算法相同，只是单位换成词。

辅助指标

- PSNR / SSIM：只在合成数据上算，用来看复原本身的质量
- 角点检测成功率：只用于透视矫正，看角点找得准不准
- 每页的 CER 分布：自采页数不多，除了均值，也要画出每页的分布，避免被个别页拉偏

实验矩阵：每一行都要带和不带预处理对比，也要比较“原版方法”和“针对自采数据改进后”的版本，这是 handout 明确要求的。

缺陷	对比组	数据	指标
运动模糊	无处理 / Wiener / Wiener（改进参数）/ Richardson-Lucy	公开数据集、自采、合成	CER、WER；合成上加 PSNR、SSIM
阴影	无处理 / 背景除法加 Sauvola / 同态滤波 / Retinex / 自适应核改进版	公开数据集、自采、合成	CER、WER；合成上加 PSNR、SSIM
透视畸变	无处理 / 轮廓角点加单应 / Hough 加 RANSAC / 带兜底策略的改进版	公开数据集、自采、合成	CER、WER、角点成功率
三种叠加	P0 到 P6 共 7 种顺序	自采叠加组、合成叠加	CER、WER

每个传统方法都要做参数扫描（例如 Wiener 的 K、形态学核大小、Hough 的投票阈值），画出参数对 CER 的影响曲线，这是报告里“讨论”部分的主要材料。可选的 AI 参考线如果做，就在同样的数据和指标上多加一行。

7. 分阶段计划

项目切成七个阶段，每个阶段结束都有能检查的交付物。阶段之间不绑定具体日期，做完一个再进下一个，课程的硬节点列在本节末尾。

阶段 0：立项与环境

- **任务**：向老师或助教确认单人可行；完成报名；装好 Python、OpenCV、scikit-image、Tesseract 和 CER / WER 计算库；写好评测脚本
- **交付物**：单人确认的回复 ；能对一张图输出 CER 和 WER 的评测脚本
- **完成标准**：评测脚本在一张测试图上跑通

阶段 1：数据采集与基线

- **任务**：挑 30 页 PDF 并打印；按第 5 节的协议拍摄；整理文件名和元数据；下载公开数据集；跑不做预处理的 OCR 基线
- **交付物**：约 360 张自采图、元数据 CSV、各条件下的基线 CER
- **完成标准**：模糊、阴影、透视三种条件的基线 CER 都明显高于清晰基准，说明缺陷确实在拖累 OCR；如果某种条件差别很小，就重拍

阶段 2：预实验与 proposal

- **任务**：每种缺陷各实现一个最简版本（Wiener、背景除法、轮廓角点加单应），在几张图上确认能跑；写 proposal
- **交付物**：三个最简原型；proposal
- **完成标准**：三个原型都能让至少一部分图的 CER 下降。handout 没写 proposal 的长度和格式，需要问助教

阶段 3：主方法与中期展示

- **任务**：把三种缺陷的主方法做完整；先做透视和阴影（相对直接），模糊的 PSF 估计放在后面；按课程安排报名中期展示；做展示材料
- **交付物**：三种缺陷各有主方法的初步结果；中期展示 slides
- **完成标准**：每种缺陷都有“带与不带预处理”的 CER 对比，哪怕还很粗糙。这一步也是检查点，没达到就按第 8 节的顺序裁剪

阶段 4：中期展示

- **任务**：展示初步结果，记录老师和同学的反馈；按要求在截止前上传 slides
- **交付物**：已上传的中期展示
- **完成标准**：按反馈列出后续要改的地方

阶段 5：对照方法、改进与组合实验

- **任务**：实现三种缺陷的第二个传统方法；做针对自采数据的改进；参数扫描；合成数据实验；P0 到 P6 的顺序消融；同时开始写报告里方法和数据两节；按课程安排报名终展
- **交付物**：完整的实验结果表和曲线；报告的方法与数据章节初稿
- **完成标准**：第 6 节实验矩阵里的每一行都有数

阶段 6：终展与报告

- **任务**：做终展并上传 slides；之后补全报告的结果、讨论、结论和贡献说明
- **交付物**：终展 slides；最终报告
- **完成标准**：报告按 handout 列的章节齐全，贡献一栏写明 100%

课程的硬节点（来自 handout，只是提醒，不是排期）

- 10/6：组队表截止
- 11/3 晚 11:59：proposal 截止

- 11/10：中期展示报名截止；11/18–20 展示，11/20 晚 11:59 前上传
- 11/24：终展报名截止；12/5–7 展示，12/7 晚 11:59 前上传
- 12/11 晚 11:59：最终报告截止

8. 风险与范围裁剪

单人做三种缺陷工作量偏大，计划里在中期展示前留了一个检查点，进度落后就按下面的顺序砍。 把范围砍到两种缺陷仍然满足 handout 的要求（每人研究独立的 artifact，并讨论组合）。

风险	应对
老师不同意单人	10/6 前确认；若要求组队，按 artifact 切分，每人认领一种
拍出来的缺陷太轻，基线 CER 没差别	阶段 1 先拍一小批试跑基线，再决定要不要加重缺陷后重拍
模糊的 PSF 估计不稳定	先在合成数据（PSF 已知）上验证 Wiener 实现，再上真实图；估不准时用已知 PSF 当上界，报告里写明
Tesseract 对某类文档（如小票）本身就差	按文档类型分别汇报 CER，不混在一起算
公开数据集下载不了或许可不允许	阶段 1 前核对；拿不到就用自采加合成数据代替，并在报告里说明
进度落后	中期展示前检查进度，按下面的顺序裁剪

裁剪顺序（先砍排在前面的）

1. 不做 AI 参考线
2. 每种缺陷的公开数据集只保留一个
3. 去掉可选的进阶方法：L0 盲去模糊、单尺度 Retinex
4. 合成数据实验只做叠加这一项
5. 砍掉一种缺陷，保留模糊加阴影，或模糊加透视，看哪个进度更好；模糊最贴课程内容，不建议砍

9. 最终报告结构与贡献说明

报告章节直接照 handout 列的顺序写，每一章的素材在本计划里都已经有了。 报告 12/11 晚 11:59 前提交。

报告章节	要写的内容	素材来源
标题与成员	项目名、作者	第 1 节
引言与动机	手机拍文档为什么难识别，三种缺陷各自怎么来	第 1 节、第 3 节的退化模型
已有方法回顾	每种缺陷常见方法的优缺点	第 3 节，阶段 2 查文献时补充
提出的方法	三条预处理流水线的细节、针对自采数据的改进、数据集	第 3 节、第 5 节
仿真与对比	实验结果、与其他方法的对比、讨论	第 4 节、第 6 节
结论与未来工作	结论、局限、可以接着做的方向（如 AI 方法、弯曲纸张）	阶段 6
各成员贡献	贡献百分比	下面

贡献说明：单人完成，报告里写 100%。如果最后被要求组队，改成按实际分工写百分比，handout 说项目成绩会按相对贡献加权。